

Domux 智能家居控制模型

评测技术报告

结构化指令生成任务

版本	v1.0
日期	2026-06-25

基于 Gemma 4-E2B-IT ·SFT + RL 两阶段训练

摘要 Abstract

本报告评测一个面向智能家居控制场景的 **E2B** 专用模型 **Domux**。模型基于 Google **Gemma 4-E2B-IT** 基座，经过监督微调（**SFT**）+ 强化学习（**RL**）训练流程，专门优化智能家居指令解析任务。模型接收自然语言指令，输出标准化的七字段结构化控制指令 **action|device|attribute|value|unit|room|floor**，并支持一句话包含多个控制意图（输出多条指令）。

我们构建了一套覆盖单意图 / 多意图 / 省略属性 / 非常规命名四个维度的测试集，共 **4057** 条样本，与 **11** 个主流模型进行横向对比，包括 Qwen3.5 系列（2B-27B）、同源 Gemma 系列及主流闭源 API（DeepSeek/Claude/Gemini）。

核心结论

本 **E2B** 专用模型在智能家居控制任务上展现出四大核心优势：

1

跨级超越：本模型准确率（**98.37%**）显著超越 Qwen3.5-27B（81.4%）、Gemma 4-31B（85.2%）等大尺寸通用模型。

2

媲美闭源、零调用成本：在专用任务准确率上反超 DeepSeek-V4（90.3%）、Claude Haiku 4.5（91.4%）、Gemini 3.5 Flash（88.7%）等主流闭源 API，领先 7-10 个百分点，且格式合格率达 **100.00%**，本地部署、零 API 费用、延迟更低，适合在算力受限的智能家居边缘设备上规模化落地。

3

推理性能优异：推理延迟极低（单意图 **130ms**、多意图 **210ms**），满足实时语音交互需求。

4

通用能力无损：与基座 Gemma 4-E2B-IT 的 A/B 对照显示，微调后通用能力保留率达 **97%-105%**（中英文知识不降反升、数学推理持平），且 32703 条非控制输入 零格式误触发，证明专用微调未引发灾难性遗忘。

Contents

1 任务定义 Task Definition 3

1.1 任务描述 3

1.2 输出格式规范 3

1.3 输入输出示例 3

2 测试集构建 Test Set Construction 3

2.1 数据来源与构建方式 3

2.2 测试集设计 4

2.3 规模与分布 4

3 评测协议 Evaluation Protocol 4

3.1 推理设置 4

3.2 评测指标 4

4 模型对比评测 Model Evaluation 5

4.1 模型表现 5

4.2 部署方式对比 7

4.3 量化方式对比 7

4.4 通用能力验证 8

5 模型性能评测 Model Performance 9

5.1 推理延迟（单并发基线） 9

5.2 并发性能测试 10

5.3 性能特征分析 11

6 结论 Conclusion 11

1

任务定义Task Definition

1.1

任务描述

模型接收用户自然语言指令（英文），输出标准化的七字段结构化控制指令。字段以 | 分隔，缺省字段以 * 占位。当一句指令包含多个控制目标时，输出多条指令，每条指令独立成行。

1.2

输出格式规范

字段	含义	取值示例	缺省处理
action	动作	set / turnOn / turnOff / adjustUp / adjustDown / activate	不可缺省
device	设备	AC / LED Strip / Curtain / Ceiling Light	不可缺省
attribute	属性	mode / temperature / brightness / color / position	*
value	取值	Cool / 26 / 50 / Blue	*
unit	单位	Celsius / Percent / Kelvin	*
room	房间	Living Room / Guest Bedroom / Majlis	*
floor	楼层	Ground Floor / First Floor	*

Table 1: 七字段格式规范

多意图支持：一句输入含多个控制目标时输出多条指令，每条指令独立成行。评测时多条指令按集合比对，不计顺序。

1.3

输入输出示例

测试类别	类别说明	用户输入	标准输出 (gold)
单意图	单个指令只控制一个设备	set the ac in the guest bedroom on the ground floor to dry mode	set AC mode Dry * Guest Bedroom Ground Floor
多意图	单个指令控制多个设备	set the aircon to cool and open the shades halfway in the guest bedroom	set AC mode Cool * Guest Bedroom * set Shade position 50 Percent Guest Bedroom *
省略属性	指令只表明控制的设备，但缺少具体属性值	dim the reading light	adjustDown Reading Light brightness * * * *
非常规命名	非标准设备名映射，如复数等	close the blinds in the bedroom halfway	set Blind position 50 Percent Bedroom *

Table 2: 输入输出示例

2

测试集构建Test Set Construction

2.1

数据来源与构建方式

- 构建方式：基于真实智能家居场景需求，采用线上真实数据（70%）+ LLM 场景补充（20%）+ 人工边界数据（10%）的混合构建方式。线上真实数据来自用户实际使用场景，经抽取整理后保留自然语言特征；LLM 场景补充针对性生成训练集未覆盖的设备组合和表达方式；人工边界数据聚焦多意图、省略属性、非常规命名等复杂 case。

- 标注与质量保证：人工逐条标注，LLM 严格判断格式与质量（字段合法性、逻辑一致性），最后由人工逐条复检，确保测试集质量。

2.2 测试集设计

测试集围绕影响指令解析难度的关键因素设计，划分为 4 个互斥类别，每条样本归属唯一类别：

- 单意图：用户输入仅含单个控制目标，模型输出 1 条控制指令。
- 多意图：用户一句话包含多个控制目标，模型输出多条控制指令（每条独立成行），并正确处理房间/楼层的继承关系。
- 省略属性：用户表达简洁、省略部分属性，模型需推断或以 * 缺省占位，输出完整字段。
- 非常规命名：用户使用非标准设备命名或口语化表达，模型需映射到规范设备词表，输出标准化设备名。

2.3 规模与分布

类别	条数	占比	核心考察点
单意图	1122	27.7%	单条指令的字段抽取准确性
多意图	1641	40.4%	多指令拆分 + 房间/楼层继承
省略属性	735	18.1%	字段缺省推断
非常规命名	559	13.8%	非标准命名的词表映射
总计	4057	100%	—

Table 3: 测试集规模与分布（总规模 4057 条）

3 评测协议 Evaluation Protocol

3.1 推理设置

- 本模型训练方式：基于 Google Gemma 4-E2B-IT 基座模型进行监督微调（SFT）+ 强化学习（RL）两阶段训练。SFT 阶段在自建智能家居指令-标准答案数据上进行有监督学习，使模型掌握七字段输出格式与领域词汇规范；RL 阶段以输出格式合法性、字段准确率、多意图拆分质量为奖励信号，进一步提升结构化输出的稳定性与边界 case 处理能力。
- 推理框架与硬件：VLLM v0.6.3，单张 NVIDIA A100（80GB），FP16 精度，显存利用率 gpu-memory-utilization=0.3，Ubuntu 22.04，CUDA 12.1。
- 采样参数：temperature = 0.0（贪心解码），top-p = 1.0，max tokens = 256。
- 对手模型推理：开源模型（Qwen3.5 系列、Gemma 4 系列）采用 vLLM 本地部署，FP16 精度，推理设置与本模型一致；闭源模型（DeepSeek-V4 / Claude Haiku 4.5 / Gemini 3.5 Flash）通过官方 API 调用，temperature=0。所有对手均使用统一 system prompt（规则约束 + 七字段格式说明），不做领域微调。

3.2 评测指标

基于全量 gold 标准答案，计算以下指标：

类别	指标名称	定义	计算方式
准确性	格式合格率	输出可正确解析为 7 字段的比例	按行拆分，每行必须正好 7 个字段（6 个 ）
	结果准确率	样本整体完全正确的比例	单指令 = 该行 7 字段全对；多指令 = 指令集合全对（不计顺序）
	槽位 F1	字段级抽取的精确率与召回率的调和平均	$2 \cdot P \cdot R / (P + R)$ ，P= 正确槽位/预测槽位，R= 正确槽位/标准槽位
	意图 F1	指令级匹配的调和平均（仅多意图）	$2 \cdot P \cdot R / (P + R)$ ，P= 正确指令/输出指令，R= 正确指令/标准指令
性能	平均耗时	单条样本的纯推理耗时（扣除网络传输）	按单意图/多意图分组统计平均值（不混合平均）

Table 4: 评测指标定义

槽位 F1 衡量字段级抽取质量，意图 F1 衡量多意图指令匹配能力。

4

模型对比评测

Model Evaluation

4.1

模型表现

我们选取本模型基座 **Gemma 4-E2B-IT**（微调前对照）、主流开源 **Qwen3.5** 系列（覆盖 2B 到 27B 多档尺寸）、同源 **Gemma 4** 系列（E4B / 12B / 31B，验证基座模型通用版本表现）和主流闭源大模型（DeepSeek-V4 / Claude Haiku 4.5 / Gemini 3.5 Flash）作为对比基线，在相同测试集、相同评测协议、相同判定规则下进行横向对比。

多维度对比结果

智能家居控制专用任务 + 通用能力参考

Benchmark	Domux (E2B)	基座	Qwen 3.5-2B	Qwen 3.5-4B	Gemma 4-E4B	Qwen 3.5-9B	Gemma 4-12B	Qwen 3.5-27B	Gemma 4-31B	Deep Seek- V4	Claude Haiku 4.5	Gemini 3.5 Flash
智能家居控制（专用任务）												
结果准确率 (%)	98.37	45.2	53.3	63.2	66.7	73.2	77.8	81.4	85.2	90.3	91.4	88.7
└ 单意图	99.64	60.4	69.5	77.9	80.8	85.5	88.4	91.7	92.6	96.1	96.5	94.8
└ 多意图	98.05	38.2	44.5	55.8	60.4	68.3	72.8	77.3	82.6	87.5	89.6	86.5
└ 省略属性	99.05	50.6	57.7	67.8	71.3	76.6	81.6	85.7	88.3	93.6	94.5	92.3
└ 非常规命名	95.89	30.9	38.4	48.3	52.7	60.4	66.7	70.3	75.5	81.6	83.8	79.9
格式合格率 (%)	100.0	81.6	87.8	91.6	92.5	94.9	96.4	97.2	97.8	99.0	99.5	98.5
槽位 F1(%)	99.64	73.5	78.5	84.2	85.8	88.9	91.2	92.8	94.5	96.1	96.8	95.3
意图 F1-多意图 (%)	98.96	51.8	61.9	71.8	74.4	80.4	84.5	86.7	90.5	93.5	93.7	91.5
平均延迟 (ms, 单/多)	130/210	130/210	290/410	410/570	420/590	710/990	910/1270	1660/2320	1860/2600	1200/1680	900/1260	700/980
通用能力（参考）												
C-Eval(%)	57.9	55.0	63.3	69.6	52.9	77.8	65.4	83.3	72.6	87.7	75.1	77.6
MMLU 5-shot(%)	66.5	65.0	60.8	68.2	63.6	74.8	73.3	81.2	81.8	88.2	83.5	81.6
GSM8K 0-shot(%)	63.3	65.0	58.5	70.4	60.3	81.8	77.7	89.2	85.7	91.7	89.5	87.3
模型规格												
参数量	E2B	E2B	2B	4B	E4B	9B	12B	27B	31B	671B	闭源	闭源
基座	Gemma4	—	通用	通用	Gemma4	通用	Gemma4	通用	Gemma4	通用	通用	通用
类型	SFT+RL	基座	通用	通用	通用	通用	通用	通用	通用	通用	通用	通用
部署	本地	本地	本地	本地	本地	本地	本地	本地	本地	API	API	API

注：DeepSeek-V4 为 671B（37B 激活）MoE 架构；Claude Haiku 4.5 与 Gemini 3.5 Flash 为闭源 API。




Figure 1: 智能家居控制任务——各模型准确率对比

结论 本模型（98.37%）在专用任务上全面领先——较同尺寸通用模型领先 45pp，反超 27B/31B 大模型，并超越闭源 API 7-10pp；格式合格率 100%，延迟仅 130/210ms。专用微调在小参数量下实现了远超尺寸的任务能力。

4.2 部署方式对比

不同推理框架下的准确率对比（均使用 FP16 精度）：

部署方式	结果准确率	格式合格率	槽位 F1	意图 F1	延迟 (单/多)	说明
VLLM (baseline)	98.37%	100.00%	99.64%	98.96%	130/210	基线配置
SGLang	98.35%	100.00%	99.62%	98.94%	117/189	RadixAttention 优化，延迟降低约 10%

Table 5: 部署方式对比

结论 两种主流框架准确率几乎一致（差异 <0.2pp），模型表现不依赖特定推理框架；SGLang 延迟更优，VLLM 部署更简便，均可作为生产部署选择。

4.3 量化方式对比

不同数值精度下的准确率对比（均使用 VLLM 部署）：

量化方式	结果准确率	格式合格率	槽位 F1	意图 F1	相对基线	说明
FP16 (baseline)	98.37%	100.00%	99.64%	98.96%	—	基线精度
BF16	98.35%	100.00%	99.62%	98.94%	-0.02pp	几乎无损
INT8	97.90%	99.80%	99.20%	98.50%	-0.47pp	轻微损失，显存减半，延迟降 18%
INT4	96.50%	99.20%	98.30%	97.20%	-1.87pp	明显损失，显存降 75%，延迟降 35%

Table 6: 量化方式对比

结论 模型对量化具备良好鲁棒性。BF16/INT8 可作为生产首选（准确率损失 $\leq 0.5\text{pp}$ ，显存大幅降低）；即使激进的 INT4 量化准确率仍保持 96.5%，适合极端显存受限的边缘场景。格式合格率为各精度下均 $\geq 99\%$ ，结构化输出能力稳定。

4.4 通用能力验证

为验证 SFT+RL 专用微调是否损伤基座的原有通用能力，以基座 **Gemma 4-E2B-IT** 为基准线，采用 **A/B** 对照在相同数据集、相同判定规则下对比微调前后表现。能力保留率 = 微调准确率 / 基座准确率。

维度	数据集	样本量	微调模型	基座	保留率	结论
中文学科知识	C-Eval	12342	57.9%	55.0%	105.2%	不降反升
英文知识	MMLU	14042	66.5%	65.0%	102.3%	不降反升
数学推理	GSM8K	1319	63.3%	65.0%	97.4%	基本持平
格式误触发	非控制输入	32703	0 误触发	—	—	零泄漏 100%

Table 7: 通用能力保留率




Figure 2: 通用能力保留率与格式泄漏验证

结论 微调后通用能力保留率达 97%-105%（中英文不降反升、数学持平），且 32703 条非控制输入零格式误触发。SFT+RL 专用微调”有得无失”，未引发灾难性遗忘。

5.1 推理延迟（单并发基线）

按意图数量分组统计延迟：

指标	单意图	多意图
平均延迟	130 ms	210 ms
中位数	128 ms	205 ms
P90 / P95 / P99	142 / 146 / 172 ms	229 / 235 / 405 ms
最小 / 最大	101 / 186 ms	168 / 405 ms
标准差	11.5 ms	26.0 ms

Table 8: 推理延迟统计

单意图延迟稳定（标准差仅 11.5ms），多意图 P95 仍在 235ms 内；单/多意图的耗时差异主要来自输出长度，而非任务难度。

意图数量与耗时的关系：模型采用自回归生成，耗时主要由输出 token 数决定。实测显示耗时随意图数近似线性增长：

意图数	平均耗时	平均输出长度
1 意图	130 ms	~48 字
2 意图	190 ms	~88 字
3 意图	250 ms	~166 字

Table 9: 意图数量与耗时

拟合关系： $\text{耗时} \approx 70 + 60 \times \text{意图数} \text{ (ms)}$ ，其中约 70ms 为固定 prefill 开销，每增加一个控制意图约增加 60ms 解码时间。即使 3 意图的复杂场景，纯推理耗时仍控制在 0.25s 以内。




Figure 3: 推理耗时与意图数的线性关系

本模型性能数据基于 A100（80GB，gpu-memory-utilization=0.3）实测，延迟为纯推理耗时（已扣除 40ms 网络传输）。模型仅占用约 10GB 显存，亦可部署于 RTX 3090/4090 等消费级显卡。

5.2 并发性能测试

单卡 A100 部署，真实场景性能压测（含网络延时）：

并发数	请求数	失败率	平均 (ms)	P95	P99	总吞吐	输出吞吐
1	200	0%	184.3	181.9	183.3	229.2	90.4
2	458	0%	215.2	183.1	184.8	391.5	154.8
3	611	0%	193.9	190.1	192.4	651.2	256.8
5	1020	0%	218.4	197.2	199.0	961.8	379.2
10	2040	0%	213.9	208.9	212.0	1952.6	770.3
20	4101	0%	217.2	214.4	216.4	3706.9	1462.4
30	6283	0%	252.9	247.2	251.4	4414.5	1741.6
40	8704	0%	290.6	280.8	287.9	4888.9	1930.9
50	10915	0%	339.8	321.2	332.4	5065.8	2000.1
60	13322	0%	373.0	357.6	368.9	5443.9	2150.3
70	15723	0%	440.6	422.3	435.7	5239.3	2069.9
80	18206	0%	477.7	453.4	469.5	5521.7	2181.6
90	19942	0%	579.3	557.1	573.5	5037.6	1989.5
100	22591	0%	697.7	660.1	686.5	4628.3	1828.2

Table 10: 并发性能测试结果（吞吐量单位 token/s）




Figure 4: 并发性能：吞吐量与延迟随并发数变化（单卡 A100）

关键指标：

- 平均输入/输出 **token**：25.7 / 16.7 token
- 首字延迟（**TTFT**）：单并发 95ms，并发 60 时 254ms，并发 100 时 576ms
- 零失败率：最高并发档（100）的 22591 个请求 100% 成功（0% 失败率）

5.3 性能特征分析

吞吐量拐点：

- 最优并发区间：并发 60-80，吞吐量达到峰值平台 **~5500 token/s**（输出 ~2150 token/s）
- 并发 1→60：吞吐量线性增长（5.4x → 23.8x）
- 并发 80→100：越过峰值平台后吞吐量下降（5522 → 4628 token/s，-16%）

延迟与并发的权衡：

- **低延迟区（并发 ≤20）**：平均延迟 184~218ms，P99 < 220ms，适合实时交互场景
- **高吞吐区（并发 50~80）**：平均延迟 340~478ms，吞吐量 5000+ token/s，峰值 ~5500 token/s，适合批量推理场景
- **饱和区（并发 ≥90）**：延迟急剧上升（579~698ms），吞吐量越过峰值后下降，不推荐

稳定性表现：

- 零失败：全部 124116 个请求（跨 14 个并发档位）100% 成功，无超时/崩溃
- 首字延迟可控：即使并发 100 时，TTFT 中位数 576ms，仍在 1 秒以内
- 尾部延迟稳定：P99 与 P95 差距小（并发 60 时仅 11ms），无长尾抖动

6 结论 Conclusion

在智能家居结构化指令生成这一垂直任务上，**Domux**（E2B 专用模型）通过与 11 个主流模型（微调前基座 Gemma 4-E2B-IT、开源 Qwen3.5 系列 2B/4B/9B/27B、同源 Gemma 4 系列 E4B/12B/31B、闭源 DeepSeek-V4 / Claude Haiku 4.5 / Gemini 3.5 Flash）的横向对比，展现出多个层面的显著优势：

- 微调前后跃升（**SFT+RL** 价值）：本模型（98.37%）较微调前基座 Gemma 4-E2B-IT（45.2%）提升约 53 个百分点。同一基座、同一参数量，仅通过监督微调（SFT）+ 强化学习（RL）两阶段训练，即把专用任务能力从“不可用”提升至“生产级”，直接量化了垂直微调的价值。
- 跨级超越：本模型准确率（98.37%）显著超越 Qwen3.5-27B（81.4%）、Gemma 4-31B（85.2%）等大尺寸通用模型，而推理延迟仅 130/210ms。这意味着同等乃至更高的准确率下，部署成本远低于大模型。
- 替代闭源（零成本部署）：本模型在专用任务上反超 DeepSeek-V4（90.3%）、Claude Haiku 4.5（91.4%）、Gemini 3.5 Flash（88.7%）等主流闭源 API，领先 7-10 个百分点，且格式合格率达 **100.00%**、槽位 F1 **99.64%**、多意图意图 F1 **98.96%**。本模型可在边缘设备本地运行，无 API 调用费用、无网络往返延迟、无隐私外泄风险。
- 通用能力无损（无灾难性遗忘）：与基座 Gemma 4-E2B-IT 的 A/B 对照显示，微调后通用能力保留率达 **97.4%-105.2%**（C-Eval 105.2%、MMLU 102.3%、GSM8K 97.4%），中英文知识不降反升；32703 条非控制输入 零格式误触发。这证明 SFT+RL 在获得专用控制能力的同时完整保留了原有通用能力，模型可安全部署于“控制 + 通用对话”双场景。

结论 综上，本模型证明了面向特定领域的专用小模型，能够以远低于通用大模型（无论开源还是闭源）的资源成本，在目标任务上取得同等甚至更优的效果，且不牺牲原有通用能力。在智能家居边缘部署场景下，这是同时优化“准确率 / 延迟 / 成本 / 隐私”四个维度的最优解，为低成本、低延迟、本地化的语音控制方案提供了可行路径。